


Dibuat untuk memenuhi tugas Dasar Sistem Cerdas

ADALINE (Adaptive Linear Neuron)



Dosen pembimbing: Fauzan Arrofiqi, S.T, M.T.

Disusun oleh:
Windy Deftia M
07311640000015

Teknik Biomedik
Institut Teknologi Sepuluh Nopember
2018

PEMBAHASAN


DASAR TEORI

Jaringan Syaraf Tiruan

Pemodelan jaringan neural dilakukan dengan pembelajaran dan penyesuaian dari suatu objek dengan tujuan untuk mengenali pola-pola dalam data dan menstimulasikan proses belajar adaptif biologis. Dalam memodelkan jaringan neural hal yang perlu diperhatikan adalah banyaknya spesifikasi yang akan diidentifikasi. Model jaringan neural terdiri dari beberapa neuron dan sejumlah masukan untuk menirukan fungsi-fungsi dasar logika. Model-model jaringan neural ini dapat diklasifikasikan menjadi beberapa kriteria diantaranya: menurut metode pembelajaran, menurut *outputnya*, menurut tipe arsitekturnya, dll. Permodelan jaringan neural menurut metode pembelajarannya dibagi menjadi 2 yakni: dengan pengawasan dan tanpa pengawasan. Sedangkan permodelan jaringan neural menurut arsitekturnya dapat dibagi menjadi: feedforward dan berulang. Yang terakhir adalah permodelan jaringan neural menurut *outputnya* yaitu biner dan berulang. Jaringan syaraf tiruan yang pertama kali dikenalkan adalah model McCulloch Pitts pada tahun 1943. Kemudian, pada tahun 1960 Widrow dan Hoff menemukan metode ADALINE (Adaptive Linear Neuron)


Mengadopsi dari sistem dasar biologis manusia, syaraf tiruan dapat digambarkan sebagai berikut:

1. Menerima *input* atau yang mempunyai bobot (*weight*)
2. Setiap sel syaraf mempunyai sebuah nilai ambang (*threshold*). Jumlah bobot dari *input* dikurangi dengan nilai ambang, maka akan mendapatkan suatu sinyal aktivasi dari sel syaraf (post synaptic potential, PSP, dari sel syaraf). Sinyal aktivasi kemudian menjadi fungsi aktivasi untuk menghasilkan *output* dari sel syaraf.




Beberapa fungsi aktivasi untuk menentukan suatu *output* dari syaraf adalah


1. Hard limit



2. Linear



3. Log Sigmoid



Berikut macam-macam fungsi aktivasi lainnya yang disajikan dalam bentuk tabel:

Name	Input/Output Relation	Icon	MATLAB Function
Hard Limit	$a = 0 \quad n < 0$ $a = 1 \quad n \geq 0$		hardlim
Symmetrical Hard Limit	$a = -1 \quad n < 0$ $a = +1 \quad n \geq 0$		hardlims
Linear	$a = n$		purelin
Saturating Linear	$a = 0 \quad n < 0$ $a = n \quad 0 \leq n \leq 1$ $a = 1 \quad n > 1$		satlin
Symmetric Saturating Linear	$a = -1 \quad n < -1$ $a = n \quad -1 \leq n \leq 1$ $a = 1 \quad n > 1$		satlins
Log-Sigmoid	$a = \frac{1}{1 + e^{-n}}$		logsig
Hyperbolic Tangent Sigmoid	$a = \frac{e^n - e^{-n}}{e^n + e^{-n}}$		tansig
Positive Linear	$a = 0 \quad n < 0$ $a = n \quad 0 \leq n$		poslin
Competitive	$a = 1 \quad \text{neuron with max } n$ $a = 0 \quad \text{all other neurons}$		compet

Adaline

Adaline atau yang biasa dikenal dengan *Adaptive Linear Neuron* merupakan salah satu metode untuk pembelajaran Jaringan Neural Buatan. Sebelum jaringan neural buatan melakukan identifikasi, jaringan tersebut mengalami pembelajaran guna menentukan bobot yang diinginkan. Adaline sendiri dikembangkan oleh Widrow dan Hoff pada tahun 1960. Pada metode adaline, pembelajaran dilatih dengan menggunakan aturan delta, yang juga dikenal sebagai aturan *Least Mean Squares* (LMS).

- Karakteristik

Metode adaline memiliki beberapa karakteristik, diantaranya:

- Jaringan terdiri dari satu atau lebih unit masukan dan satu unit keluaran.
- Mempunyai sebuah bias yang berperilaku seperti bobot yang bisa disesuaikan yang terletak pada koneksi dari sebuah unit yang selalu mengeluarkan sinyal +1 agar bobot bias bisa dilatih seperti bobot lainnya dengan proses yang sama dalam algoritma pelatihan.

- Beberapa jaringan Adaline yang menerima sinyal dari unit masukan yang sama dalam dikombinasikan menjadi sebuah jaringan lapis tunggal.

- Fungsi aktivasi

$$y = \begin{cases} 1 & \text{jika } net \geq 0 \\ -1 & \text{jika } net < 0 \end{cases}$$

- Adaline Metode

1. Metode 1

Variabel yang digunakan:

$$v(k) = \sum_{i=0}^n w_i(k)x_i(k)$$

-

$$e(k) = d(k) - v(k)$$

-

$$w_i(k+1) = w_i(k) + \mu e(k)x_i(k)$$

-

Dimana:

➤ $x(k)$ = *input*

➤ $d(k)$ = *desired level*

➤ $y(k)$ = *output* yang didapatkan dengan membandingkan $v(k)$ dengan fungsi aktivasi

- Algoritma Pembelajaran

- Langkah 1: Inisialisasi bobot μ
- Langkah 2: Set nilai aktivasi dari unit masukan
- Langkah 3: Hitung total masukan ke unit keluaran
- Langkah 4: Gunakan fungsi aktivasi

2. Metode 2

Variabel yang digunakan:

$$v(k) = \sum_{i=0}^n w_i(k)x_i(k)$$

$$y(k) = f_{bs}(v(k)) = \frac{1}{1 + e^{-\alpha v(k)}}$$

$$e(k) = d(k) - y(k)$$

$$w_i(k+1) = w_i(k) + \mu e(k)x_i(k)$$

Dimana:

- $x(k)$ = *input*
- $d(k)$ = *desired level*
- $y(k)$ = *output* yang didapatkan dengan membandingkan $v(k)$ dengan fungsi aktivasi
- $w(k)$ = *weight*

- Algoritma Pembelajaran
 - Langkah 1: Inisialisasi bobot μ dan α
 - Langkah 2: Set nilai aktivasi dari unit masukan
 - Langkah 3: Hitung total masukan ke unit keluaran
 - Langkah 4: Gunakan fungsi aktivasi

3. Metode 3

Variabel yang digunakan

$$v(k) = \sum_{i=0}^n w_i(k) x_i(k)$$

$$y(k) = f_{bs}(v(k)) = \frac{1}{1 + e^{-av(k)}}$$

$$e(k) = d(k) - y(k)$$

$$\mu(k) = \frac{\mu_0}{1 + \frac{k}{\tau}}$$

$$MSE(k) = \frac{1}{2} [e(k)]^2$$

$$w_i(k+1) = w_i(k) + \mu(k) e(k) x_i(k)$$

Dimana:

- $x(k)$ = *input*
- $d(k)$ = *desired level*
- $y(k)$ = *output* yang didapatkan dengan membandingkan $v(k)$ dengan fungsi aktivasi
- $w(k)$ = *weight*
- $\mu(k)$ = konstanta pembelajaran
- MSE = *error*

- Algoritma Pembelajaran


- Langkah 1: Inisialisasi bobot μ , α , dan τ
- Langkah 2: Set nilai aktivasi dari unit masukan
- Langkah 3: Hitung total masukan ke unit keluaran
- Langkah 4: Gunakan fungsi aktivasi

PEMBAHASAN

1. ADALINE Metode 1

Pada program ADALINE Metode 1 ini menggunakan prinsip ADALINE yang sudah dibahas sebelumnya yakni melakukan update weight untuk menemukan weight optimum, sehingga grafik terus berjalan seiring nilai Miu dan Epsilon, yang mana pada metode ini Miu serta Epsilon sangat memengaruhi kecepatan pembelajaran syaraf tiruan dan MSEnya.

Berikut adalah bentuk program dari ADALINE Metode 1 yang telah dibuat pada *software* "Codetyphon".




2. ADALINE Metode 2

Miu	Alpha	Ep	MSE	Epoch
0,9	0,5	0,001	0,000996875	488
	0,1		0,000999488	2491
	0,3		0,000997850	822
	0,8		0,000994503	300
	1		0,000993991	237
0,1	0,5	0,001	0,000999703	4494
0,2			0,000999173	2241
0,4			0,000998667	1114
0,6			0,000999034	738
0,8			0,000999184	550


1			0,000995621	438
0,9	0,5	0,003	0,002998628	275
		0,005	0,004964328	210
		0,008	0,007951971	162
		0,01	0,009951266	143

Dari tabel diatas maka dapat dilihat untuk perubahan variabel μ , α , dan epsilon (ep).


- Ketika variabel μ dan ep tetap, sedangkan α diubah maka semakin besar harga α semakin kecil Epoch (kecepatan pembelajaran), yang artinya syaraf tiruan semakin cepat pembelajarannya. Begitupula dengan MSEnya, semakin besar α maka error yang ada semakin kecil.



- Ketika α dan ep tetap sedangkan μ diubah, maka semakin tinggi harga μ semakin cepat pembelajaran syaraf tiruan. Hal tersebut tidak berlaku pada MSE karena ketika diuji dengan μ yang semakin lama semakin besar MSE tidak stabil. Hal tersebut dapat dilihat dalam grafik berikut:



- Yang terakhir ada pengujian ketika harga μ dan α tetap sedangkan ϵ diubah. Semakin besar ϵ maka semakin cepat pembelajaran syaraf tiruan sedangkan harga MSEnya semakin besar. Hal tersebut menyatakan error akan semakin besar jika epsilon semakin besar




3. ADALINE Metode 3

Miu 0	Tau	Alpha	Ep	MSE	K
2,5	1000000	1	0,0001	4,93E-05	1043
1				4,94E-05	2771
3,5				4,89E-05	691


5				4,89E-05	323
2,5	500000	1	0,0001	4,94E-05	1043
	1500000			4,93E-05	1043
	2000000			4,93E-05	1043
2,5	1000000	0,5	0,0001	4,93E-05	2199
		2		4,92E-05	323
		5		1,55E-06	23
2,5	1000000	1	0,0005	0,000243	439
			0,001	0,00048	299
			0,01	0,004433	79

Dari tabel diatas maka dapat dilihat untuk perubahan variabel μ_0 , α , τ , dan epsilon (ep).


- Ketika α , τ , dan ep tetap, sedangkan μ_0 diubah. Semakin besar harga μ_0 maka semakin kecil iterasi yang ada atau dapat disimpulkan jika pembelajaran semakin cepat. Hal tersebut juga berlaku pada harga MSE, semakin besar μ_0 maka error yang ada semakin kecil pula.




- Ketika μ_0 , α , dan ep tetap, sedangkan τ diubah. Untuk nilai τ yang besar maka iterasi yang ada cenderung tetap/ tidak berubah. Sedangkan harga MSE semakin kecil ketika τ semakin besar.



- Ketika μ_0 , τ , dan ϵ_p tetap, sedangkan α diubah. Semakin besar harga α maka semakin kecil iterasi dan MSEnya



- Ketika μ_0 , τ , dan α tetap, sedangkan ϵ_p diubah. Semakin besar harga ϵ_p maka semakin besar pula error yang ada namun pembelajaran cepat. Disamping itu, dari data yang didapat, perubahan pada ϵ_p memiliki dampak yang cukup besar pada MSE. Hal itu dapat dilihat pada grafik berikut:



KESIMPULAN

1. Parameter yang ada seperti α τ μ dan epsilon dapat mempengaruhi kecepatan pembelajaran syaraf buatan. Hal ini dapat ditunjukkan dengan banyaknya iterasi atau epoch yang ada.
2. Perubahan nilai pada parameter juga dapat menyebabkan tingkat kesalahan dalam memodelkan gerbang logika menjadi besar, maka dari itu dibutuhkan suatu percobaan untuk menentukan nilai konstanta yang efektif dengan kecepatan pembelajaran yang tidak terlalu lama dan tingkat kesalahan perhitungan kecil

REFERENSI

https://erlinwin.files.wordpress.com/2012/05/adaline_madaline.pdf